

AV2 BIG DATA >>>>>>

Deteccção de Fraudes em Cartões de Crédito

ARTHUR LINS

LUCAS FERNANDES

VICTOR AROUCHA

Introdução

Problema central:

Construção de um sistema para identificar automaticamente transações suspeitas de fraude.

Desafios:

- Desbalanceamento Extremo: Mais de 284 mil transações normais para apenas 492 fraudes ($< 0.2\%$ do total).
- Variáveis Transformadas: Colunas V1 a V28 derivadas da Análise de Componentes Principais (PCA).
- Simulação de Big Data: O problema exige processamento e modelagem típicos de ambientes com alto volume e velocidade de dados.



Motivação

Tentativas de fraude em bancos batem recorde no 1º tri, diz Serasa



Foram quase 2 milhões de tentativas, 21,5% a mais do que no primeiro trimestre de 2024

Caroline Aragaki, do Estadão Conteúdo

12/06/25 às 15:29 | Atualizado 12/06/25 às 15:29

O dataset é baseado em transações reais de clientes europeus (Set/2013), mantendo a privacidade, utilizando PCA.

Com o advento da tecnologia, cada vez mais o uso de dinheiro físico vem reduzindo, transicionou-se ao modelo de transação digital automatizado ou por uso de transações por cartões de crédito. Portanto, isso abre oportunidade para tentativas de fraude, ou roubo de forma anônima nessas transações, sendo forte ameaça, no contexto atual à confiança em decisões automatizadas e operações empresariais.

Dito isso, nosso dataset se encontra relevante especialmente na atualidade, como podemos ver a seguir:


Fonte: <https://www.cnnbrasil.com.br/economia/financas/tentativas-de-fraude-em-bancos-somam-quase-2-milhoes-no-1o-tri-recorde-da-serie-diz-serasa/>

Objetivo do Projeto

Construir um modelo de machine learning capaz de detectar com precisão transações fraudulentas (Classe 1) em um dataset de cartões de crédito, superando o desafio do extremo desequilíbrio de classes.

A partir da implementação de modelos de classificação (como Random Forest e XGBoost) focados em métricas de desempenho que priorizem a detecção da classe minoritária (como ROC AUC e Recall).

Pipeline de Dados



Ingestão → Análise → Limpeza → Preparação → Modelagem.




Modelagem de dados

Feature Engineering


Classes

Grande desbalanceamento entre as classes



Fracionamento do Dataset

Equilibrar as classes para não enviesar o modelo.






Dimensionalidade

Nos utilizamos de **3 técnicas de redução de dimensionalidade** para visualizar a diferença nas propriedades entre as classes:



- **PCA**
- **T-SNE**
- **Truncated SVD**

a partir dessa visualização é possível interpretar que a classe fraude tem comportamento altamente distinto e forma grupos concentrados, enquanto a classe normal é mais dispersa.



AR

A autoregressão foi utilizada como feature adicional modelo baseline de regressão logística, usado como Auto-Regression Model (AR Model) para comparação, e incluída como feature nos modelos classificadores.





Classificadores

Modelos testados

Dentre os diferentes modelos classificadores testados, os que melhor performaram foram:

RandomForest e XGBoost.

Métricas Utilizadas:

ROC AUC, Precisão, Recall e **F1-Score**

Resultados

Ambos os modelos performaram bem na classificação, com alto valor de precisão e ROC AUC.

RandomForest

- ROC AUC: 0.97
- Precisão: 0.89 | 0.93
- Recall: 0.93 | 0.88

XGBoost

- ROC AUC: 0.98
- Precisão: 0.92 | 0.93
- Recall: 0.93 | 0.91

=== RandomForest ===					
ROC AUC: 0.9721706864564007					
		precision	recall	f1-score	support
	0	0.8942	0.9394	0.9163	99
	1	0.9355	0.8878	0.9110	98
	accuracy			0.9137	197
	macro avg	0.9149	0.9136	0.9136	197
	weighted avg	0.9148	0.9137	0.9136	197

=== XGBoost ===					
ROC AUC: 0.9819624819624819					
		precision	recall	f1-score	support
	0	0.9208	0.9394	0.9300	99
	1	0.9375	0.9184	0.9278	98
	accuracy			0.9289	197
	macro avg	0.9291	0.9289	0.9289	197
	weighted avg	0.9291	0.9289	0.9289	197

Conclusão

O trabalho permitiu compreender de forma prática os desafios envolvidos na detecção de fraudes em cartões de crédito, um problema marcado por forte desbalanceamento e padrões comportamentais complexos, sem relação necessária com o tempo.

De forma geral, a solução construída mostra que o uso combinado de análise exploratória, balanceamento e algoritmos de aprendizado supervisionado pode produzir modelos eficientes e confiáveis para apoiar sistemas reais de detecção de fraude.





**Que cada dia seja
inesquecível.**
